

# SANNOLIKHETSLÄRA OCH STATISTIK

## FÖRELÄSNING 8

Mattias Villani

**Avdelningen för Statistik och Maskininlärning  
Institutionen för datavetenskap  
Linköpings universitet**



# ÖVERSIKT

- ▶ Punktskattning
- ▶ Samplingfördelning
- ▶ Konfidensintervall
- ▶ Konfidensintervall för populationsväntevärden
- ▶ Konfidensintervall för proportioner

# PUNKTSKATTNING

- ▶ Grundproblem: sannolikhetsmodeller har **okända parametrar**,  $\theta$ .
  - ▶ Ex medelinkomsten i Sveriges: populationens väntevärde  $\mu$
  - ▶ Ex andelen defekta komponenter i produktionen av en produkt  $p$ .
  - ▶ Ex spamfilter:  $\beta_0$  och  $\beta_1$  är parametrar

$$\Pr(\text{Spam}|\text{antal\$}) = \frac{\exp(\beta_0 + \beta_1 \cdot \text{antal\$})}{1 + \exp(\beta_0 + \beta_1 \cdot \text{antal\$})}$$

- ▶ Vi vill använda (tränings)data för att bestämma värden för dessa parametrar.
- ▶ **Punktskattning**: vår **bästa gissning** utifrån data.

# MOMENTMETODEN

- ▶ Ex  $X_1, \dots, X_n | \lambda \stackrel{iid}{\sim} \text{Poisson}(\mu)$ .  $E(X) = \mu$ .
- ▶ Rimlig punktskattning av populationväntevärdet  $\mu$ :

$$\hat{\mu} = \bar{x}$$

- ▶ **Moment** av ordningen  $k = 1, 2, \dots$

$$\mu_k = \mathbb{E}(X^k)$$

- ▶ **Samplemoment** av ordningen  $k$

$$m_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

- ▶ Ex:  $k = 1$ :  $\mu_1 = \mu = \mathbb{E}X$  och  $m_1 = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$ .

# MOMENTMETODEN

- ▶ Momentmetoden för att skatta  $k$  modellparametrar  $\theta_1, \dots, \theta_k$ : Lös följande ekvationssystem m a p  $\theta_1, \dots, \theta_k$  :

$$\mu_1 = m_1$$

$$\mu_2 = m_2$$

$$\vdots$$

$$\mu_k = m_k$$

- ▶ Notera att  $\mu_1, \dots, \mu_k$  är funktioner av  $\theta_1, \dots, \theta_k$ . Mer korrekt:

$$\mu_1(\theta_1, \dots, \theta_k) = m_1$$

$$\mu_2(\theta_1, \dots, \theta_k) = m_2$$

$$\vdots$$

$$\mu_k(\theta_1, \dots, \theta_k) = m_k$$

# MOMENTMETODEN

- ▶ Ibland mer praktiskt att jobba med centralmoment.
- ▶ **Centralmoment** av ordningen  $k = 2, 3, \dots$

$$\mu'_k = \mathbb{E} (X - \mu_1)^k$$

- ▶ **Samplecentralmoment** av ordningen  $k$

$$m'_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

- ▶ Notera att  $\mu'_2 = \text{Var}(X)$  och

$$m'_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \neq \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

# MOMENTMETODEN - BETA EXEMPEL

- Ex  $X_1, \dots, X_n | \alpha, \beta \stackrel{iid}{\sim} \text{Beta}(\alpha, \beta)$ :

$$\mu_1 = \mathbb{E}X = \frac{\alpha}{\alpha + \beta}$$

$$\mu_2 = \mathbb{E}(X^2) = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)}$$

- Momentskattningar: lös för  $\alpha$  och  $\beta$

$$\frac{\alpha}{\alpha + \beta} = m_1$$

$$\frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)} = m_2$$

$$\text{ger } \hat{\alpha} = \frac{m_1(m_2 - m_1)}{m_1^2 - m_2} \text{ och } \hat{\beta} = \frac{(m_1 - m_2)(m_1 - 1)}{m_1^2 - m_2}.$$

# MAXIMUM LIKELIHOOD-METODEN

- ▶ **Maximum likelihood (ML) estimatorn:** Välj det  $\theta$  som maximerar sannolikheten för data:

$$\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} P(x_1, \dots, x_n | \theta)$$

- ▶ Kontinuerliga fallet:

$$\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} f(x_1, \dots, x_n | \theta)$$

- ▶ **Likelihoodfunktionen** är sannolikheten för stickprovet sett som en funktion av parametern



$$L(\theta) = P(x_1, \dots, x_n | \theta)$$

- ▶ ML-estimatorn maximerar  $L(\theta)$ .
- ▶ Ex data från Bernoulli med sannolikhet  $p$ :  
 $X_1 = 0, X_2 = 1, X_3 = 1, X_4 = 0, X_5 = 1$ .

$$L(p) = (1 - p)pp(1 - p)p = p^3(1 - p)^2$$



# MAXIMUM LIKELIHOOD - BERNOULLIEXEMPEL



# MAXIMUM LIKELIHOOD-METODEN

- ▶ Vi kan hitta **ML-skattningen** analytiskt: Lös m a p  $\theta$

$$\frac{\partial L(\theta)}{\partial \theta} = 0.$$

- ▶ Oftast enklare att **maximera log-likelihoodfunktionen**

$$\frac{\partial \ln L(\theta)}{\partial \theta} = 0$$

- ▶ Ex Bernoulli:

$$\frac{\partial \ln L(p)}{\partial p} = \frac{\partial}{\partial p} (s \ln p + f \ln(1 - p)) = \frac{s}{p} + f \frac{-1}{1 - p} = \frac{s}{p} - \frac{f}{1 - p} = 0$$

vilket ger lösningen  $\hat{p} = \frac{s}{s+f} = \frac{s}{n}$ .

- ▶ Kontrollera  $\hat{p}$  är ett maximum - andraderivatan är negativ i  $p = \hat{p}$

$$\frac{\partial^2 \ln L(\theta)}{\partial \theta^2} = -\frac{s}{p^2} - \frac{f}{(1 - p)^2} < 0$$

för alla  $p \in [0, 1]$ , inklusive  $p = \hat{p}$ .

# ML-METODEN

- Notera att oberoende data är praktiskt

$$L(\theta) = \prod_{i=1}^n f(x_i|\theta)$$

så log-likelihooden blir en summa

$$\ln L(\theta) = \sum_{i=1}^n \ln f(x_i|\theta).$$

- Ex:  $X_1, \dots, X_n | \lambda \stackrel{iid}{\sim} \text{Exp}(\lambda)$  ger

$$L(\lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum_{i=1}^n x_i}$$

och

$$\frac{\partial \ln L(\lambda)}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i = \frac{n}{\lambda} - n\bar{x},$$

och därmed  $\hat{\lambda} = 1/\bar{x}$ .

# SAMLINGFÖRDELNINGEN

- ▶ Hur bra är en **estimator**  $\hat{\theta}$ ?
- ▶ **Väntevärdesriktig**?  $\mathbb{E}\hat{\theta} = \theta$ .
- ▶  $\text{Bias}(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta$ .
- ▶ **Samplingfördelningen** beskriver variationen i  $\hat{\theta}$  över alla stickprov av en viss storlek  $n$ .
- ▶ **Standardfelet** för  $\hat{\theta}$  är  $\sqrt{\text{Var}(\hat{\theta})}$ , dvs standardavvikelsen för  $\hat{\theta}$  över alla stickprov av storleken  $n$ .
- ▶ **Mean Squared Error** (MSE):

$$MSE(\hat{\theta}) = \mathbb{E} (\hat{\theta} - \theta)^2 = \text{Var}(\hat{\theta}) + [\text{Bias}(\hat{\theta})]^2$$

# SAMLINGFÖRDELNINGEN

- ▶ Ex. Poisson. ML-estimator för  $\mu$ :  $\bar{X}$ .
- ▶ Väntevärdesriktig:  $\mathbb{E}(\hat{\mu}) = \mu$  och  $\text{Var}(\hat{\mu}) = \frac{\sigma^2}{n} = \frac{\mu}{n}$ .
- ▶ Notera att  $\text{Var}(\hat{\mu}) = \frac{\mu}{n}$  beror på den okända parametern  $\mu$ . Lösning: sätt  $\mu = \hat{\mu} = \bar{x}$ .
- ▶ Två vanliga tekniker för att räkna ut samplingfördelningen för en estimator  $\hat{\theta}$ :
  - ▶ **Centrala gränsvärdessatsen:**  $\hat{\theta} \stackrel{\text{approx}}{\sim} N[\theta, \text{Var}(\hat{\theta})]$ .
  - ▶ **Bootstrapsimulering.**
- ▶ **Bootstrap:**
  - ▶ Skapa  $N$  **bootstrapstickprov**  $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(N)}$  av samma storlek som det ursprungliga stickprovet genom dragning **med återläggning**.
  - ▶ Beräkna estimatet  $\hat{\theta}(\mathbf{x}^{(1)}), \dots, \hat{\theta}(\mathbf{x}^{(N)})$  för var och ett av dessa  $N$  stickprov.
  - ▶ Den empiriska fördelningen för  $\hat{\theta}(\mathbf{x}^{(1)}), \dots, \hat{\theta}(\mathbf{x}^{(N)})$  (tänk histogram) är en approximation av samplingfördelningen för  $\hat{\theta}$ .


# KONFIDENSINTERVALL

- ▶ Punktskattning ger bara en bästa gissning för  $\theta$ . Konfidensintervall är ett försök att beskriva osäkerheten om  $\theta$ .
- ▶ **95%-igt konfidensintervall** för  $\theta$  är ett intervall  $[a, b]$  sådant att

$$P\{a \leq \theta \leq b\} = 0.95.$$

- ▶ Viktigt: det är **intervallet** som är **slumpmässigt**. Parametern  $\theta$  är en fix konstant.
- ▶ **Tolkning**: ett 95%-igt konfidensintervall  $[a, b]$  kommer att **täcka** ( $\theta \in [a, b]$ ) parametervärdet  $\theta$  i 95% av alla möjliga stickprov.
- ▶ Man kan naturligtvis ha andra **konfidensnivåer** än 95%. 90%, 95% och 99% är vanligast. Se den lite klumpiga allmänna notationen  $(1 - \alpha) \cdot 100\%$ -igt konfidensintervall i Baron.

# KONFIDENSINTERVALL



# KONFIDENSINTERVALL - STANDARDPROCEDUR

- ▶ Standardprocedur för att skapa ett 95%-igt konfidensintervall.
- ▶ Antag normalfördelad väntevärdesriktig estimator  $\hat{\theta}$ . Då gäller

$$Z = \frac{\hat{\theta} - \theta}{\sigma(\hat{\theta})} \sim N(0, 1)$$

- ▶ Låt  $z_{0.975}$  vara 97.5% percentilen i  $N(0, 1)$  fördelningen. Tabell A4 i Baron ger att  $z_{0.975} = 1.96$ .
- ▶ Då gäller att

$$\mathbf{P} \left\{ -z_{0.975} \leq \frac{\hat{\theta} - \theta}{\sigma(\hat{\theta})} \leq z_{0.975} \right\} = 0.95$$

vilket kan skrivas om som

$$\mathbf{P} \{ \hat{\theta} - z_{0.975} \cdot \sigma(\hat{\theta}) \leq \theta \leq \hat{\theta} + z_{0.975} \cdot \sigma(\hat{\theta}) \} = 0.95$$

- ▶ Alltså:  $[\hat{\theta} - z_{0.975} \cdot \sigma(\hat{\theta}), \hat{\theta} + z_{0.975} \cdot \sigma(\hat{\theta})]$  är ett 95%-igt konfidensintervall för  $\theta$ .



# KONFIDENSINTERVALL FÖR POPULATIONSVÄNTEVÄRDET

- ▶  $\theta = \mu$ .  $\hat{\theta} = \bar{X}$ .  $\sigma(\hat{\theta}) = \text{Std}(\bar{X}) = \sigma / \sqrt{n}$ .  $\sigma$  antas känd.
- ▶ Centrala gränsvärdessatsen ger att  $\hat{\theta} = \bar{X}$  är approximativt normalfördelad när  $n$  är stort ( $n \geq 30$ ). Oavsett hur data är fördelade.
- ▶ Alltså:  $\bar{X} \pm z_{0.975} \cdot \frac{\sigma}{\sqrt{n}}$  är ett (approximativt) 95%-igt konfidsintervall för  $\theta$ .
- ▶ **Bestämning av stickprovsstorlek  $n$ .** Vi kan bestämma  $n$  så att vi får ett konfidsintervall av given bredd.

# KONFIDENSINTERVALL - OKÄNT STANDARDFEL

- ▶ I praktiken är  $\sigma(\hat{\theta})$  inte känd utan måste skattas (estimeras) från data. Ex:  $Std(\bar{X}) = \sigma/\sqrt{n}$  och  $\sigma$  är ofta okänd.
- ▶ Vid stora stickprov (stort  $n$ ) får vi ett bra approximativt konfidsensintervall genom att ersätta  $\sigma(\hat{\theta})$  med en skattning. T ex  $s/\sqrt{n}$  istället för  $\sigma/\sqrt{n}$ .
- ▶ Konfidsensintervall för populationsväntevärdet  $\mu$  vid **små stickprov** en **normalfördelad population**:

$$t = \frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t_{n-1}(0, 1)$$

- ▶ Så ett exakt 95%-igt konfidsensintervall för  $\mu$  ges då av

$$\bar{X} \pm t_{0.025}(n-1) \frac{s}{\sqrt{n}}$$

där  $t_{0.025}(n-1)$  är 2.5% percentilen i  **$t$ -fördelningen** med  $\nu = n - 1$  frihetsgrader. Läs av från Tabell A5 i Baron.

# KONFIDENSINTERVALL FÖR EN ANDEL

- ▶ Ex. 196 av 2000 utfrågade svarar att de röstar på centerpartiet. Hur stor andel  $p$  röstar på centerpartiet i hela populationen?
- ▶  $\hat{p} = 0.098$  är ML-skattningen. Med hur säkra är vi?
- ▶  $\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i$  där  $X_i = 1$  om den  $i$ :te utfrågade person röstar på centerpartiet och  $X_i = 0$  annars. Så  $\hat{p}$  är också ett medelvärde!
- ▶ Antag att  $X_i \stackrel{iid}{\sim} \text{Bernoulli}(p)$ . Då gäller  $\mathbb{E}X_i = p$  och  $\text{Var}(X_i) = p(1 - p)$ . Alltså

$$\mathbb{E}\hat{p} = p \quad \text{Var}(\hat{p}) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{n^2} np(1 - p) = \frac{p(1 - p)}{n}.$$

- ▶  $\sigma(\hat{p})$  beror på  $p$ , som vi ersätter med en skattning:  
 $s(\hat{p}) = \sqrt{\hat{p}(1 - \hat{p})/n}$ .
- ▶ Centrala gränsvärdessatsen ger ett approximativt  $(1 - \alpha)100\%$ -igt intervall

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$