

# TDAB01 Sannolikhetslära och Statistik

Jose M. Peña  
IDA, Linköpings Universitet

Föreläsning 10

- ▶ **Bayesiansk inferens**
- ▶ **Bernoullimodell med beta prior**
- ▶ **Normalmodell med normal prior**
- ▶ **Multinomialmodell med Dirichlet prior**
- ▶ **Bayesiansk estimator, konfidensintervall och hypotestest**

# Frekventistisk inferens

- ▶ Hittills på kursen: **Frekventistisk inferens**.
  - ▶ **Parametrar**  $\theta$  är **fixa** (icke slumpmässiga) storheter.
  - ▶ **Data är slumpvariabler**:  $f(x_1, \dots, x_n | \theta)$ .
- ▶ Frekventistisk inferens: Hur en **metod** betar sig över **upprepade stickprov** från populationen.
- ▶ **Samplingfördelningar** är i fokus, dvs vilka värden kan min estimator förväntas anta för olika stickprov ?
- ▶ **Väntevärderiktighet**: Min skattningsmetod kommer att vara korrekt i genomsnitt, dvs sett över alla möjliga stickprov.
- ▶ **Konfidensintervall**: Min intervallskattningsmetod kommer att täcka det sanna parametervärdet  $\theta$  i 95% av alla möjliga stickprov från populationen.
- ▶ **Hypotestest**: Min testmetod kommer bara att dra fel slutsats i 5% av alla stickprov om nollhypotesen är sann.

# Subjektiva sannolikheter

- ▶ Du **vet inte** värdet på en populationsparameter  $\theta$ . Du är **osäker** om  $\theta$ . Påståendet  $P(\theta \leq 2)$  är meningsfullt.
- ▶ **Det är osäkerheten som är relevant**. Om  $\theta$  är en fix, konstant, storhet eller ej spelar ingen roll.
- ▶ Jag vet inte 10:e decimalen av  $\pi$ . Då kan jag säga

$$P(10 : \text{e decimal av } \pi = 9) = 1/10$$

- ▶ Det är **min** osäkerhet som spelar roll. Du kanske vet 10:e decimalen av  $\pi$ . För mig är  $\pi$  osäker och jag kan prata om sannolikhetsfördelningen för 10:e decimalen av  $\pi$ .
- ▶ Sannolikheter är ett **subjektivt** mått på personlig **grad av tilltro**.
- ▶ **Bayesiansk statistik** bygger på ett subjektivt sannolikhetsbegrepp.

## Thomas Bayes 1701-1761



# Bayesiansk inferens

- ▶ Bernoullimodellen:  $X_1, \dots, X_n | \theta \sim \text{Bernoulli}(\theta)$ . T ex slantsingling.
- ▶ Sannolikheten  $\theta$  för krona är okänd.
- ▶ Innan vi har börjat singla slant beskriver jag min osäkerhet om  $\theta$  med min **apriorifördelning**:  $\pi(\theta)$ .
- ▶ **A priori** = **före** (före jag har observerat data).
- ▶ Antag nu att vi har observerat ett antal slantsinglingar  $X_1 = x_1, \dots, X_n = x_n$ . T ex 0, 0, 1, 1, 0.
- ▶ Hur bör vi **uppdatera** vår apriorifördelning med denna datainformation ?  
Hur **lärt** vi oss från data ?
- ▶ **Aposteriorifördelning**:  $\pi(\theta | x_1, \dots, x_n)$ .
- ▶ **A posterior** = **efter** (efter jag har observerat data).
- ▶ Bayesiansk inferens **betingar på observerade data**. Då  $P(\text{Okänt} | \text{Känt})$ .

## Bayes sats uppdaterar prior till posterior: Diskreta fallet

- ▶ Antag att  $\theta$  bara kan anta värdena  $0.1, 0.2, \dots, 0.9$  (diskretisering).
- ▶ Kom ihåg **Bayes sats** för händelser  $A$  och  $B$ :

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- ▶ Låt t ex  $A = \{\theta = 0.1\}$  och  $B = \{X = x\}$ .
- ▶ Bayes sats ger **posteriorfördelningen**:




$$P(\theta = 0.1|x) = \frac{P(x|\theta = 0.1)P(\theta = 0.1)}{P(x)}$$

där satsen om total sannolikhet ger

$$P(x) = P(x|\theta = 0.1)P(\theta = 0.1) + \dots + P(x|\theta = 0.9)P(\theta = 0.9)$$




- ▶ **Prior:**  $P(\theta = 0.1)$
- ▶ **Likelihood:**  $P(x|\theta = 0.1)$
- ▶ **Posterior:**  $P(\theta = 0.1|x)$

## Bernoullimodell med $s=2$ och $f=3$








## Bernoullimodell med $s=20$ och $f=30$



## Bernoullimodell med $s=200$ och $f=300$



## Bayes sats uppdaterar prior till posterior: Kontinuerliga fallet

- ▶ Diskretisering så att  $\theta \in \{\theta_1, \theta_2, \dots, \theta_K\}$

$$P(\theta = \theta_i | x) = \frac{P(x | \theta = \theta_i) P(\theta = \theta_i)}{\sum_{j=1}^K P(x | \theta = \theta_j) P(\theta = \theta_j)}$$

- ▶ Finare och finare grid ( $\theta_{i+1} - \theta_i \rightarrow 0$ ) ger

$$f(\theta | x) = \frac{P(x | \theta) f(\theta)}{\int P(x | \theta) f(\theta) d\theta}$$

- ▶ **Bayes sats** för **kontinuerlig** parameter  $\theta$

$$\pi(\theta | x) = \frac{f(x | \theta) \pi(\theta)}{\int f(x | \theta) \pi(\theta) d\theta}$$

- ▶ **Prior:**  $\pi(\theta)$
- ▶ **Likelihood:**  $f(x | \theta)$
- ▶ **Posterior:**  $\pi(\theta | x)$

# Subjektivitet och objektivitet

- ▶  $\pi(\theta)$  är en **subjektiv** fördelning som varierar från person till person baserat på erfarenhet, osv.
- ▶ **Hur vi lär oss från data**, dvs uppdaterar från prior till posterior, bestäms av Bayes sats.
- ▶ **Uppdateringmekanismen är objektiv** (matematik).
- ▶ Resultat: När  $n \rightarrow \infty$  (**stora datamängder**) kommer alla personers posteriors att konvergera till samma fördelning. Objektivitet genom **subjektivt konsensus**.
- ▶ Vid rapportering av resultat kan man använda **icke-informativa** apriorifördelningar (dvs svag information) eller priorinformation som är lättförståelig.
- ▶ Maskininlärning: Mycket vanligt med aprioriinformation av typen "Jag tror att den okända funktionen är **mjuk**, men jag vet inte mycket mer om den exakta funktionsformen".

## Bernoullimodell med beta prior

- ▶ Bernoullimodellen:  $X_1, \dots, X_n | \theta \sim \text{Bernoulli}(\theta)$ . **Likelihood:**  $\theta^s (1 - \theta)^f$ .
- ▶  $\theta \in [0, 1]$ . Lämplig **prior**:  $\theta \sim \text{Beta}(\alpha, \beta)$ , dvs

$$\pi(\theta) = \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}$$

- ▶ **Posterior:**

$$\begin{aligned} \pi(\theta | x) &= \frac{f(x|\theta)\pi(\theta)}{\int f(x|\theta)\pi(\theta)d\theta} = \frac{\theta^s (1 - \theta)^f \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}}{\int \theta^s (1 - \theta)^f \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1} d\theta} \\ &= \frac{\theta^{\alpha+s-1} (1 - \theta)^{\beta+f-1}}{\int \theta^{\alpha+s-1} (1 - \theta)^{\beta+f-1} d\theta} = c \cdot \theta^{\alpha+s-1} (1 - \theta)^{\beta+f-1} \end{aligned}$$

där  $c = 1 / \int \theta^{\alpha+s-1} (1 - \theta)^{\beta+f-1} d\theta$  är en konstant (beror inte på  $\theta$ ).

- ▶ En täthet på formen  $c \cdot \theta^{\alpha+s-1} (1 - \theta)^{\beta+f-1}$  känns igen som en  $\text{Beta}(\alpha + s, \beta + f)$ :

$$\pi(\theta | x) = \frac{1}{B(\alpha + s, \beta + f)} \theta^{\alpha+s-1} (1 - \theta)^{\beta+f-1}$$

## Bayes sats på proportionell form

- ▶ Notera att vi aldrig behövde räkna ut nämnaren i Bayes sats,  $\int f(x|\theta)\pi(\theta)d\theta$ . Vi kände igen betafördelningen ändå.
- ▶ Tätheter måste integrera till ett. Proportionalitetskonstanter kan vi "strunta i".
- ▶ Enklare form av Bayes sats:

$$\pi(\theta|x) \propto f(x|\theta)\pi(\theta)$$





$$\text{Posterior} \propto \text{Likelihood} \times \text{Prior}$$

## Exempel: Spam data

- ▶ George har gått igenom 4601 mejl, och 1813 av dessa var spam.
- ▶ **Modell:** Låt  $x_i = 1$  om det i:te mejlet var spam. Antag  $x_i | \theta \stackrel{iid}{\sim} \text{Bernoulli}(\theta)$ .
- ▶ **Prior:**  $\theta \sim \text{Beta}(\alpha, \beta)$ .
- ▶ **Posterior:**  $\theta | \mathbf{x} \sim \text{Beta}(\alpha + 1813, \beta + 2788)$ .

## Exempel: Spam data ( $n=10$ ) med fyra olika priors





- Grön: Prior. Blå: Normaliserad likeli hood. Röd: Posterior.









## Exempel: Spam data (n=100) med fyra olika priors

- Grön: Prior. Blå: Normaliserad likelihoed. Röd: Posterior.



## Exempel: Spam data ( $n=4601$ ) med fyra olika priors

- ▶ Grön: Prior. Blå: Normaliserad likelihoed. Röd: Posterior.



## Normalmodell med normal prior

- ▶ **Modell:**  $X_1, \dots, X_n \stackrel{iid}{\sim} N(\theta, \sigma^2)$  med  $\sigma^2$  **känd**.

- ▶ **Prior:**

$$\theta \sim N(\mu, \tau^2)$$

- ▶ **Posterior:**

$$\begin{aligned} P(\theta|x_1, \dots, x_n) &\propto P(x_1, \dots, x_n|\theta, \sigma^2)p(\theta) \\ &\propto N(\theta|\mu_x, \tau_x^2) \end{aligned}$$

där

$$\frac{1}{\tau_x^2} = \frac{n}{\sigma^2} + \frac{1}{\tau^2}$$

$$\mu_x = w\bar{x} + (1 - w)\mu$$

och

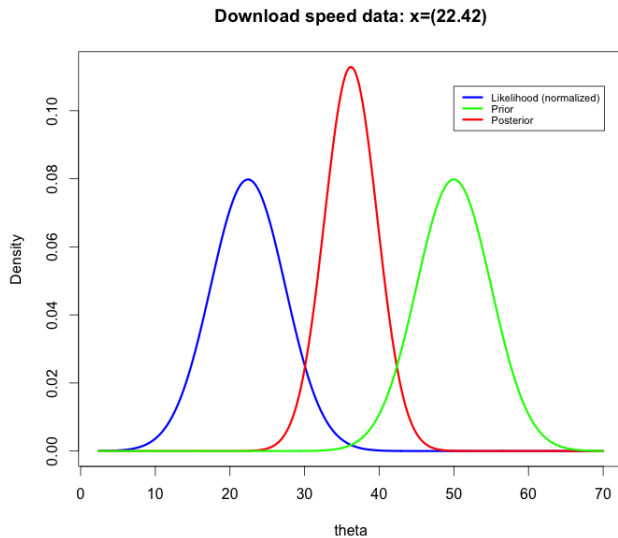
$$w = \frac{\frac{n}{\sigma^2}}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}}$$

- ▶ Posterior precision = Data precision + Prior precision.
- ▶ Posterior väntevärde =  $\frac{\text{Data precision}}{\text{Posterior precision}}(\text{Data medelvärde}) + \frac{\text{Prior precision}}{\text{Posterior precision}}(\text{Prior väntevärde})$
- ▶ Se sida 344 i Baron för en härledning.


## Exempel: Nedladdningshastigheter

- ▶ Data:  $x = (22.42, 34.01, 35.04, 38.74, 25.15)$ .
- ▶ Modell:  $X_1, \dots, X_5 \sim N(\theta, \sigma^2)$ .
- ▶ Antag  $\sigma = 5$  (mätningar kan variera  $\pm 10$  MBit med 95% sannolikhet).
- ▶ Min prior:  $\theta \sim N(50, 5^2)$ .

## Exempel: Nedladdningshastigheter ( $n=1$ )




## Exempel: Nedladdningshastigheter ( $n=2$ )




## Exempel: Nedladdningshastigheter ( $n=3$ )

Download speed data:  $x=(22.42, 34.01, 35.04)$



## Exempel: Nedladdningshastigheter ( $n=5$ )





## Multinomialmodell med Dirichlet prior

- ▶ *Data*:  $y = (y_1, \dots, y_K)$  där  $y_k$  = antalet observationer i den  $k$ :te klassen.
- ▶ Exempel:  $K = 8$ , och  $y_k$  antal som röstar på parti  $k$  i en valundersökning med  $n = \sum_{k=1}^K y_k$  tillfrågade personer.
- ▶ Generalisering av binomial till flera klasser.
- ▶ **Multinomial modell**:  $y = (y_1, \dots, y_K) \sim \text{Multinomial}(n; \theta_1, \dots, \theta_K)$

$$p(y|\theta) \propto \prod_{k=1}^K \theta_k^{y_k} \text{ där } \sum_{k=1}^K \theta_k = 1$$


- ▶ **Dirichlet prior**:  $\theta = (\theta_1, \dots, \theta_K) \sim \text{Dirichlet}(\alpha_1, \dots, \alpha_K)$

$$p(\theta) \propto \prod_{k=1}^K \theta_k^{\alpha_k - 1}$$

- ▶ **Dirichlet posterior**:  $\theta|y \sim \text{Dirichlet}(\alpha_1 + y_1, \dots, \alpha_K + y_K)$
- ▶ När prior och posteriorfördelningarna tillhör samma familj, säger vi att priorfördelningen är **konjugerad** till den data modellen, t ex Dirichlet fördelningen är konjugerad till den multinomiala fördelningen.

# Dirichletfördelningen

- Generalisering av betafördelning till flera dimensioner.



- Väntevärde** för  $\theta = (\theta_1, \dots, \theta_K) \sim \text{Dirichlet}(\alpha_1, \dots, \alpha_K)$

$$\mathbb{E}(\theta_k) = \frac{\alpha_k}{\sum_{j=1}^K \alpha_j}$$

- Variansen minskar för större  $\alpha$ -värden. **Icke-informativ** prior har små värden, t ex  $\alpha_k = 1$  för alla  $k$ .

## Exempel: Marknadsandelar

- ▶ En undersökning bland 513 smartphone-ägare gav:
  - ▶ 180 föredrar en iPhone.
  - ▶ 230 föredrar en Androidtelefon.
  - ▶ 62 föredrar en Blackberrytelefon.
  - ▶ 41 föredrar något annat märke.
- ▶ Tidigare undersökning: iPhone 30%, Android 30%, Blackberry 20% och Annat 20%.
- ▶  $P(\text{Android har störst marknadsandel} \mid \text{Data})$  ?
- ▶ Min prior:  $\alpha_1 = 15, \alpha_2 = 15, \alpha_3 = 10$  och  $\alpha_4 = 10$ , dvs prior info motsvarar den tidigare undersökningen med 50 svarande.
- ▶ Posterior:  $(\theta_1, \theta_2, \theta_3, \theta_4) \mid y \sim \text{Dirichlet}(195, 245, 72, 51)$ .

## Exempel: Marknadsandelar

```
# Setting up data and prior
y <- c(180,230,62,41) # The cell phone survey data (K=4)
alpha <- c(15,15,10,10) # Dirichlet prior hyperparameters
nIter <- 1000 # Number of posterior draws

# Posterior sampling from Dirichlet posterior
thetaDraws <- rdirichlet(nIter,y + alpha)

# Posterior mean and standard deviation of Androids share (in %)
message(mean(100*thetaDraws[,2]))

## 43.5281011565501

message(sd(100*thetaDraws[,2]))

## 2.12159111747558

# Computing the posterior probability that Android is the largest
PrAndroidLargest <- sum(thetaDraws[,2] > max(thetaDraws[,c(1,3,4)]))/nIter
message(paste('Pr(Android has the largest market share) = ', PrAndroidLargest))

## Pr(Android has the largest market share) = 0.907
```

# Bayesiansk estimator, konfidensintervall och hypotestest

- ▶ Bayesiansk estimator av  $\theta$ :

$$E(\theta|x) = \int \theta \pi(\theta|x) d\theta$$

- ▶  $[a, b]$  är en 95 % Bayesianskt konfidensintervall om

$$P(\theta \in [a, b]|x) = \int_a^b \pi(\theta|x) d\theta = 0.95$$

- ▶ Bayesianskt hypotestest  $H_0 : \theta \in \Theta_0$  vs  $H_A : \theta \in \Theta_A$ . Förkasta  $H_0$  om

$$\pi(\Theta_0|x) < \pi(\Theta_A|x)$$

- ▶ **Bayesiansk inferens**
- ▶ **Bernoullimodell med beta prior**
- ▶ **Normalmodell med normal prior**
- ▶ **Multinomialmodell med Dirichlet prior**
- ▶ **Bayesiansk estimator, konfidensintervall och hypotestest**