

TDAB01 Sannolikhetslära och Statistik

Jose M. Peña
IDA, Linköpings Universitet

Föreläsning 10

- ▶ **Bayesiansk inferens**
- ▶ **Bernoullimodell med beta prior**
- ▶ **Normalmodell med normal prior**
- ▶ **Multinomialmodell med Dirichlet prior**
- ▶ **Bayesiansk estimator, konfidensintervall och hypotestest**

Frekventistisk inferens

- ▶ Hittills på kursen: **Frekventistisk inferens**.
 - ▶ **Parametrar** θ är **fixa** (icke slumpmässiga) storheter.
 - ▶ **Data är slumpvariabler**: $f(x_1, \dots, x_n | \theta)$.
- ▶ Frekventistisk inferens: Hur en **metod** betar sig över **upprepade stickprov** från populationen.
- ▶ **Samplingfördelningar** är i fokus, dvs vilka värden kan min estimator förväntas anta för olika stickprov ?
- ▶ **Väntevärderiktighet**: Min skattningsmetod kommer att vara korrekt i genomsnitt, dvs sett över alla möjliga stickprov.
- ▶ **Konfidensintervall**: Min intervallskattningsmetod kommer att täcka det sanna parametervärdet θ i 95% av alla möjliga stickprov från populationen.
- ▶ **Hypotestest**: Min testmetod kommer bara att dra fel slutsats i 5% av alla stickprov om nollhypotesen är sann.

Subjektiva sannolikheter

- ▶ Du **vet inte** värdet på en populationsparameter θ . Du är **osäker** om θ . Påståendet $P(\theta \leq 2)$ är meningsfullt.
- ▶ **Det är osäkerheten som är relevant.** Om θ är en fix, konstant, storhet eller ej spelar ingen roll.
- ▶ Jag vet inte 10:e decimalen av π . Då kan jag säga

$$P(10 : \text{e decimal av } \pi = 9) = 1/10$$

- ▶ Det är **min** osäkerhet som spelar roll. Du kanske vet 10:e decimalen av π . För mig är π osäker och jag kan prata om sannolikhetsfördelningen för 10:e decimalen av π .
- ▶ Sannolikheter är ett **subjektivt** mått på personlig **grad av tilltro**.
- ▶ **Bayesiansk statistik** bygger på ett subjektivt sannolikhetsbegrepp.

Thomas Bayes 1701-1761



Bayesiansk inferens

- ▶ Bernoullimodellen: $X_1, \dots, X_n | \theta \sim \text{Bernoulli}(\theta)$. T ex slantsingling.
- ▶ Sannolikheten θ för krona är okänd.
- ▶ Innan vi har börjat singla slant beskriver jag min osäkerhet om θ med min **apriorifördelning**: $\pi(\theta)$.
- ▶ **A priori** = **före** (före jag har observerat data).
- ▶ Antag nu att vi har observerat ett antal slantsinglingar $X_1 = x_1, \dots, X_n = x_n$. T ex 0, 0, 1, 1, 0.
- ▶ Hur bör vi **uppdatera** vår apriorifördelning med denna datainformation ?
Hur **lä**r vi oss från data ?.
- ▶ **Aposteriorifördelning**: $\pi(\theta | x_1, \dots, x_n)$.
- ▶ **A posterior** = **efter** (efter jag har observerat data).
- ▶ Bayesiansk inferens **betingar på observerade data**. Då $P(\text{Okänt} | \text{Känt})$.

Bayes sats uppdaterar prior till posterior: Diskreta fallet

- ▶ Antag att θ bara kan anta värdena $0.1, 0.2, \dots, 0.9$ (diskretisering).
- ▶ Kom ihåg **Bayes sats** för händelser A och B :

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- ▶ Låt t ex $A = \{\theta = 0.1\}$ och $B = \{X = x\}$.
- ▶ Bayes sats ger **posteriorfördelningen**:




$$P(\theta = 0.1|x) = \frac{P(x|\theta = 0.1)P(\theta = 0.1)}{P(x)}$$

där satsen om total sannolikhet ger




$$P(x) = P(x|\theta = 0.1)P(\theta = 0.1) + \dots + P(x|\theta = 0.9)P(\theta = 0.9)$$

- ▶ **Prior:** $P(\theta = 0.1)$
- ▶ **Likelihood:** $P(x|\theta = 0.1)$
- ▶ **Posterior:** $P(\theta = 0.1|x)$




Bernoullimodell med $s=2$ och $f=3$



Bernoullimodell med $s=20$ och $f=30$



Bernoullimodell med $s=200$ och $f=300$



Bayes sats uppdaterar prior till posterior: Kontinuerliga fallet

- ▶ Diskretisering så att $\theta \in \{\theta_1, \theta_2, \dots, \theta_K\}$

$$\mathbf{P}(\theta = \theta_i | \mathbf{x}) = \frac{P(\mathbf{x} | \theta = \theta_i) \mathbf{P}(\theta = \theta_i)}{\sum_{j=1}^K P(\mathbf{x} | \theta = \theta_j) \mathbf{P}(\theta = \theta_j)}$$

- ▶ Finare och finare grid ($\theta_{i+1} - \theta_i \rightarrow 0$) ger

$$f(\theta | \mathbf{x}) = \frac{P(\mathbf{x} | \theta) f(\theta)}{\int P(\mathbf{x} | \theta) f(\theta) d\theta}$$

- ▶ **Bayes sats** för **kontinuerlig** parameter θ

$$\pi(\theta | \mathbf{x}) = \frac{f(\mathbf{x} | \theta) \pi(\theta)}{\int f(\mathbf{x} | \theta) \pi(\theta) d\theta}$$

- ▶ **Prior:** $\pi(\theta)$
- ▶ **Likelihood:** $f(\mathbf{x} | \theta)$
- ▶ **Posterior:** $\pi(\theta | \mathbf{x})$

Subjektivitet och objektivitet

- ▶ $\pi(\theta)$ är en **subjektiv** fördelning som varierar från person till person baserat på erfarenhet, osv.
- ▶ **Hur vi lär oss från data**, dvs uppdaterar från prior till posterior, bestäms av Bayes sats.
- ▶ **Uppdateringmekanismen är objektiv** (matematik).
- ▶ Resultat: När $n \rightarrow \infty$ (**stora datamängder**) kommer alla personers posteriors att konvergera till samma fördelning. Objektivitet genom **subjektivt konsensus**.
- ▶ Vid rapportering av resultat kan man använda **icke-informativa** apriorifördelningar (dvs svag information) eller priorinformation som är lättförståelig.
- ▶ Maskininlärning: Mycket vanligt med aprioriinformation av typen "Jag tror att den okända funktionen är **mjuk**, men jag vet inte mycket mer om den exakta funktionsformen".

Bernoullimodell med beta prior

- ▶ Bernoullimodellen: $X_1, \dots, X_n | \theta \sim \text{Bernoulli}(\theta)$. **Likelihood:** $\theta^s (1 - \theta)^f$.
- ▶ $\theta \in [0, 1]$. Lämplig **prior**: $\theta \sim \text{Beta}(\alpha, \beta)$, dvs

$$\pi(\theta) = \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}$$

- ▶ **Posterior:**

$$\begin{aligned} \pi(\theta | \mathbf{x}) &= \frac{f(\mathbf{x} | \theta) \pi(\theta)}{\int f(\mathbf{x} | \theta) \pi(\theta) d\theta} = \frac{\theta^s (1 - \theta)^f \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}}{\int \theta^s (1 - \theta)^f \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1} d\theta} \\ &= \frac{\theta^{\alpha+s-1} (1 - \theta)^{\beta+f-1}}{\int \theta^{\alpha+s-1} (1 - \theta)^{\beta+f-1} d\theta} = c \cdot \theta^{\alpha+s-1} (1 - \theta)^{\beta+f-1} \end{aligned}$$

där $c = 1 / \int \theta^{\alpha+s-1} (1 - \theta)^{\beta+f-1} d\theta$ är en konstant (beror inte på θ).

- ▶ En täthet på formen $c \cdot \theta^{\alpha+s-1} (1 - \theta)^{\beta+f-1}$ känns igen som en $\text{Beta}(\alpha + s, \beta + f)$:

$$\pi(\theta | \mathbf{x}) = \frac{1}{B(\alpha + s, \beta + f)} \theta^{\alpha+s-1} (1 - \theta)^{\beta+f-1}$$

Bayes sats på proportionell form

- ▶ Notera att vi aldrig behövde räkna ut nämnaren i Bayes sats, $\int f(x|\theta)\pi(\theta)d\theta$. Vi kände igen betafördelningen ändå.
- ▶ Tätheter måste integrera till ett. Proportionalitetskonstanter kan vi "strunta i".
- ▶ Enklare form av Bayes sats:

$$\pi(\theta|x) \propto f(x|\theta)\pi(\theta)$$





$$\text{Posterior} \propto \text{Likelihood} \times \text{Prior}$$

Exempel: Spam data

- ▶ George har gått igenom 4601 mejl, och 1813 av dessa var spam.
- ▶ **Modell:** Låt $x_i = 1$ om det i:te mejlet var spam. Antag $x_i|\theta \stackrel{iid}{\sim} \text{Bernoulli}(\theta)$.
- ▶ **Prior:** $\theta \sim \text{Beta}(\alpha, \beta)$.
- ▶ **Posterior:** $\theta|x \sim \text{Beta}(\alpha + 1813, \beta + 2788)$.





Exempel: Spam data ($n=10$) med fyra olika priors

- Grön: Prior. Blå: Normaliserad likeli hood. Röd: Posterior.







Exempel: Spam data (n=100) med fyra olika priors

- Grön: Prior. Blå: Normaliserad likelihoed. Röd: Posterior.



Exempel: Spam data ($n=4601$) med fyra olika priors

- Grön: Prior. Blå: Normaliserad likeli hood. Röd: Posterior.



Normalmodell med normal prior

- ▶ **Modell:** $X_1, \dots, X_n \stackrel{iid}{\sim} N(\theta, \sigma^2)$ med σ^2 **känd**.

- ▶ **Prior:**

$$\theta \sim N(\mu, \tau^2)$$

- ▶ **Posterior:**

$$\begin{aligned} P(\theta|x_1, \dots, x_n) &\propto P(x_1, \dots, x_n|\theta, \sigma^2)p(\theta) \\ &\propto N(\theta|\mu_x, \tau_x^2) \end{aligned}$$

där

$$\frac{1}{\tau_x^2} = \frac{n}{\sigma^2} + \frac{1}{\tau^2}$$

$$\mu_x = w\bar{x} + (1 - w)\mu$$

och

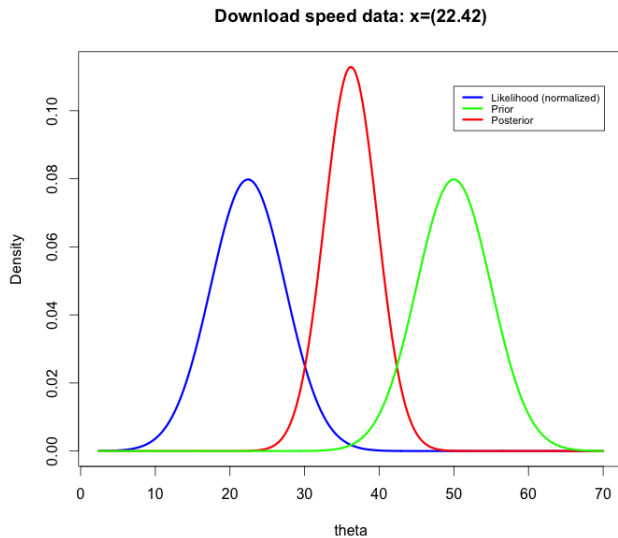
$$w = \frac{\frac{n}{\sigma^2}}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}}$$

- ▶ Posterior precision = Data precision + Prior precision.
- ▶ Posterior väntevärde = $\frac{\text{Data precision}}{\text{Posterior precision}}(\text{Data medelvärde}) + \frac{\text{Prior precision}}{\text{Posterior precision}}(\text{Prior väntevärde})$
- ▶ Se sida 344 i Baron för en härledning.


Exempel: Nedladdningshastigheter

- ▶ Data: $x = (22.42, 34.01, 35.04, 38.74, 25.15)$.
- ▶ Modell: $X_1, \dots, X_5 \sim N(\theta, \sigma^2)$.
- ▶ Antag $\sigma = 5$ (mätningar kan variera ± 10 MBit med 95% sannolikhet).
- ▶ Min prior: $\theta \sim N(50, 5^2)$.


Exempel: Nedladdningshastigheter ($n=1$)




Exempel: Nedladdningshastigheter ($n=2$)



Exempel: Nedladdningshastigheter ($n=3$)



Exempel: Nedladdningshastigheter ($n=5$)



Multinomialmodell med Dirichlet prior

- ▶ *Data*: $y = (y_1, \dots, y_K)$ där y_k = antalet observationer i den k :te klassen.
- ▶ Exempel: $K = 8$, och y_k antal som röstar på parti k i en valundersökning med $n = \sum_{k=1}^K y_k$ tillfrågade personer.
- ▶ Generalisering av binomial till flera klasser.
- ▶ **Multinomial modell**:

$$p(y|\theta) \propto \prod_{k=1}^K \theta_k^{y_k} \text{ där } \sum_{k=1}^K \theta_k = 1$$

- ▶ **Konjugerad prior**: $Dirichlet(\alpha_1, \dots, \alpha_K)$

$$p(\theta) \propto \prod_{k=1}^K \theta_k^{\alpha_k - 1}$$

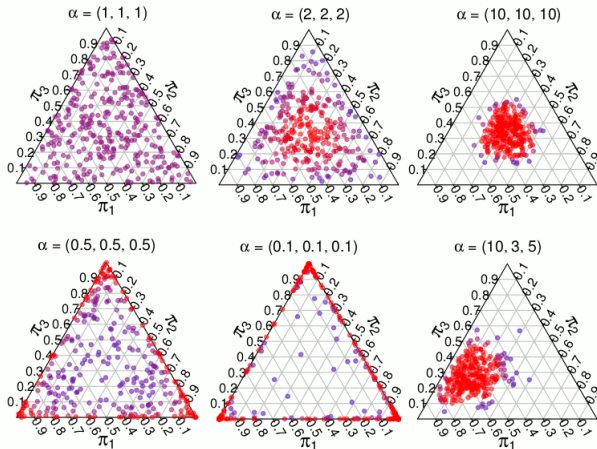
- ▶ **Väntevärde** för $\theta = (\theta_1, \dots, \theta_K) \sim Dirichlet(\alpha_1, \dots, \alpha_K)$

$$\mathbb{E}(\theta_k) = \frac{\alpha_k}{\sum_{j=1}^K \alpha_j}$$

- ▶ Variansen minskar för större α -värden. **Icke-informativ** prior har små värden, t ex $\alpha_k = 1$ för alla k .

- Generalisering av betafördelning till flera dimensioner.

Draws from a 3-dimensional Dirichlet with different α



Multinomialmodell med Dirichlet prior

- ▶ **Uppdatering** från prior till posterior:

- ▶ Modell: $y = (y_1, \dots, y_K) \sim \text{Multinomial}(n; \theta_1, \dots, \theta_K)$.
- ▶ Prior: $\theta = (\theta_1, \dots, \theta_K) \sim \text{Dirichlet}(\alpha_1, \dots, \alpha_K)$.
- ▶ Posterior: $\theta|y \sim \text{Dirichlet}(\alpha_1 + y_1, \dots, \alpha_K + y_K)$.

- ▶ **Simulering** från en Dirichlet fördelning:

- ▶ Slumpa $x_1 \sim \text{Gamma}(\alpha_1, 1), \dots, x_K \sim \text{Gamma}(\alpha_K, 1)$.
- ▶ Beräkna $z_k = x_k / (\sum_{j=1}^K x_j)$.
- ▶ $z = (z_1, \dots, z_K)$ är $\text{Dirichlet}(\alpha_1, \dots, \alpha_K)$ fördelad.

Exempel: Marknadsandelar

- ▶ En undersökning bland 513 smartphone-ägare gav:
 - ▶ 180 föredrar en iPhone.
 - ▶ 230 föredrar en Androidtelefon.
 - ▶ 62 föredrar en Blackberrytelefon.
 - ▶ 41 föredrar något annat märke.
- ▶ Tidigare undersökning: iPhone 30%, Android 30%, Blackberry 20% och Annat 20%.
- ▶ $P(\text{Android har störst marknadsandel} \mid \text{Data})$?
- ▶ Min prior: $\alpha_1 = 15, \alpha_2 = 15, \alpha_3 = 10$ och $\alpha_4 = 10$, dvs prior info motsvarar den tidigare undersökningen med 50 svarande.
- ▶ Posterior: $(\theta_1, \theta_2, \theta_3, \theta_4) \mid y \sim \text{Dirichlet}(195, 245, 72, 51)$.

Exempel: Marknadsandelar

```
# Setting up data and prior
y <- c(180,230,62,41) # The cell phone survey data (K=4)
alpha <- c(15,15,10,10) # Dirichlet prior hyperparameters
nIter <- 1000 # Number of posterior draws

# Defining a function that simulates from a Dirichlet distribution
SimDirichlet <- function(nIter, param){
  nCat <- length(param)
  thetaDraws <- as.data.frame(matrix(NA, nIter, nCat)) # Storage.
  for (j in 1:nCat){
    thetaDraws[,j] <- rgamma(nIter,param[j],1)
  }
  for (i in 1:nIter){
    thetaDraws[i,] = thetaDraws[i,]/sum(thetaDraws[i,])
  }
  return(thetaDraws)
}

# Posterior sampling from Dirichlet posterior
thetaDraws <- SimDirichlet(nIter,y + alpha)

# Posterior mean and standard deviation of Androids share (in %)
message(mean(100*thetaDraws[,2]))

## 43.5281011565501

message(sd(100*thetaDraws[,2]))

## 2.12159111747558

# Computing the posterior probability that Android is the largest
PrAndroidLargest <- sum(thetaDraws[,2] > max(thetaDraws[,c(1,3,4)]))/nIter
message(paste('Pr(Android has the largest market share) = ', PrAndroidLargest))

## Pr(Android has the largest market share) = 0.907
```

Bayesiansk estimator, konfidensintervall och hypotestest

- ▶ Bayesiansk estimator av θ :

$$E(\theta|x) = \int \theta \pi(\theta|x) d\theta$$

- ▶ $[a, b]$ är en 95 % Bayesianskt konfidensintervall om

$$P(\theta \in [a, b]|x) = \int_a^b \pi(\theta|x) d\theta = 0.95$$

- ▶ Bayesianskt hypotestest $H_0 : \theta \in \Theta_0$ vs $H_A : \theta \in \Theta_A$. Förkasta H_0 om

$$\pi(\Theta_0|x) < \pi(\Theta_A|x)$$

- ▶ **Bayesiansk inferens**
- ▶ **Bernoullimodell med beta prior**
- ▶ **Normalmodell med normal prior**
- ▶ **Multinomialmodell med Dirichlet prior**
- ▶ **Bayesiansk estimator, konfidensintervall och hypotestest**