

# SANNOLIKHETSLÄRA OCH STATISTIK

## FÖRELÄSNING 12

Mattias Villani

**Avdelningen för Statistik och Maskininlärning  
Institutionen för datavetenskap  
Linköpings universitet**



# ÖVERSIKT

- ▶ Prediktion
- ▶ Beslut

# PREDIKTION

- ▶ **Prediktion:** inferens för okända men potentiellt observerbara kvantiteter.
  - ▶ antalet buggar i en kod.
  - ▶ sjukdom.
  - ▶ mängden brytbara mineraler.
- ▶ **Prognos:** prediktion av framtida utfall.
  - ▶ lägenhetspriserna i Linköping Jan 2020.
  - ▶ framtida försäljning.
  - ▶ slutpris i en eBay auktion.

# PREDIKTION FÖR ATT UTVÄRDERA MODELLER

- ▶ Prediktion är också ett utmärkt sätt att **utvärdera** och **jämföra modeller**. En korrekt modell predikterar bra.
- ▶ **Träningsdata** - **testdata**.
- ▶ **Accuracy**: antal korrekt klassificeringar / totala antalet test data observationer.
- ▶ Handwritten digits data (3000 obs för träning, 10000 för test):
  - ▶ Multinomial regression med elastic net: accuracy = 88.49%
  - ▶ Support vector machine: accuracy: 89.42%

# PREDIKTION I REGRESSION

- ▶ Linjär regression

$$y = \beta_0 + \beta_1 x + \varepsilon, \varepsilon \sim N(0, \sigma^2)$$

- ▶ Vad blir **prediktionen** av  $Y$  för ett nytt  $x$ -värde,  $x_*$ ?

$$\mu_* = E(Y|X = x_*) = \beta_0 + \beta_1 x_*$$

som vi skattar med

$$\hat{y}_* = \hat{\beta}_0 + \hat{\beta}_1 x_*$$

- ▶ Se Baron s. 377-378 för härledning av samplingfördelning, standardfel och konfidensintervall för  $\hat{y}_*$ .
- ▶ Ett konfidensintervall för  $\hat{y}_*$  är osäkerheten om **populationens väntevärde** vid  $x = x_*$ . Dvs osäkerheten om regressionslinjen.
- ▶ Men hur ser osäkerheten för ett faktiskt  $y$ -värde ut om  $x = x_*$ ?
- ▶ **Prognosintervall** för  $Y$  när  $x = x_*$

$$\hat{\beta}_0 + \hat{\beta}_1 x_* \pm t_{\alpha/2} \cdot s \cdot \sqrt{1 + \frac{1}{n} + \frac{(x_* - \bar{x})^2}{S_{xx}}}$$

# BAYESIANSK PREDIKTION

- **Prediktiv fördelning** för ny observation  $\tilde{X}$ :

$$p(\tilde{x}|x_1, \dots, x_n) = \int f(\tilde{x}|x_1, \dots, x_n, \theta) \pi(\theta|x_1, \dots, x_n) d\theta$$

- Exempel:  $x_1, \dots, x_n | \theta \sim N(\theta, \sigma^2)$  och  $\sigma^2$  känd.
- Prediktiv fördelning

$$\tilde{x}|x_1, \dots, x_n \sim N(\mu_x, \tau_x^2 + \sigma^2)$$

- Vår bästa prognos:  $\mu_x = \mathbb{E}(\theta|x_1, \dots, x_n)$ .
- **Prediktionsvarians** = Varians pga osäkerhet om  $\theta$  ( $\tau_x^2$ ) + Varians pga osäkerhet i populationen kring  $\theta$  ( $\sigma^2$ ).
- Prediktiv fördelning genom **simulering**:
  1. Simulera parameter  $\theta^{(1)} \sim \pi(\theta|x_1, \dots, x_n)$
  2. Simulera observation  $\tilde{x} \sim f(\tilde{x}|\theta^{(1)})$
  3. Upprepa Steg 1 och 2 många ggr


# BAYESISK PREDIKTION - AR-PROCESS

- ▶ **Autoregressiv process** av första ordningen

$$y_t = \mu + \phi(y_{t-1} - \mu) + \varepsilon_t, \quad \varepsilon_t \stackrel{iid}{\sim} N(0, \sigma^2)$$


- ▶ Posterior:  $\pi(\phi, \mu, \sigma | y_1, \dots, y_T)$ .
- ▶ Vi är intresserade av  **$h$ -stegs prognosfördelningen**:  
 $p(y_{T+1}, y_{T+2}, \dots, y_{T+h} | y_1, \dots, y_T)$ .
- ▶ **Simulering** från  $p(y_{T+1}, y_{T+2}, \dots, y_{T+h} | y_1, \dots, y_T)$ :
  1. Simulera  $\theta^{(1)} = (\phi^{(1)}, \mu^{(1)}, \sigma^{(1)})$  från posteriorn  $\pi(\phi, \mu, \sigma | y_1, \dots, y_T)$
  2. Betingat på  $\theta = \theta^{(1)}$  simulera en **prognosbana**
    - ▶  $\tilde{y}_{T+1}^{(1)} \sim f(y_{T+1} | y_T, \theta^{(1)})$
    - ▶  $\tilde{y}_{T+2}^{(1)} \sim f(y_{T+2} | \tilde{y}_{T+1}^{(1)}, \theta^{(1)})$
    - ▶  $\dots$
    - ▶  $\tilde{y}_{T+h}^{(1)} \sim f(y_{T+h} | \tilde{y}_{T+h-1}^{(1)}, \theta^{(1)})$
- ▶ Upprepa steg 1 och 2 ett stort antal gånger.

# AR(1)-PROCESS





# BAYESIAN $h$ -STEP AHEAD PREDICTIVE DISTRIBUTION



# BESLUTSTEORI

- ▶ Låt  $\theta \in \Theta$  vara en **okänd kvantitet, tillstånd**.  
Exempel: Sjukdom, Global temperaturökning, antalet buggar.
- ▶ Låt  $a \in \mathcal{A}$  vara ett **beslut** (eng. action).  
Ex: operation, energisskatt, releasedatum.
- ▶ Välja beslut  $a$  när tillståndet visar sig vara  $\theta$  ger dig **nyttan** (eng. utility)

$$U(a, \theta)$$

- ▶ Alternativt: **förlust** (eng. loss):

$$L(a, \theta) = -U(a, \theta)$$

# DISKRETA TILLSTÅND, DISKRETA BESLUT

- Förlusttabell för problem med två möjliga  $\theta$ -utfall och två möjliga beslut:

	$\theta_1$	$\theta_2$
$a_1$	$L(a_1, \theta_1)$	$L(a_1, \theta_2)$
$a_2$	$L(a_2, \theta_1)$	$L(a_2, \theta_2)$

- Exempel:

	Regnigt	Soligt
Paraply	20	10
Inget paraply	50	0

# BESLUT

- ▶ **Tillståndrummet**  $\Theta$  kan vara diskret eller kontinuerligt.
- ▶ **Beslutsrummet**  $\mathcal{A}$  kan vara diskret eller kontinuerligt.
- ▶ Kontinuerligt  $\Theta$ , diskret  $\mathcal{A}$ :
  - ▶ Brobygge:  $\theta$  = grad av miljöpåverkan och  $\mathcal{A} = \{\text{bygga, ej bygga}\}$ .
- ▶ Diskret  $\Theta$ , kontinuerligt  $\mathcal{A}$ :
  - ▶  $\theta$  = antalet buggar.  $\theta \in \{0, 1, 2, \dots\}$  och  $\mathcal{A} = \text{reasetid}$ .
  - ▶ brottsdom.  $\theta \in \{\text{oskyldig, skyldig}\}$ .  $\mathcal{A} = \{\text{tid i fängelse}\}$ .
- ▶ Kontinuerligt  $\Theta$ , Kontinuerligt  $\mathcal{A}$ :
  - ▶  $\theta$  = efterfrågan på produkt,  $\mathcal{A} = \{\text{hur många enheter i lager?}\}$

# KONTINUERLIGA TILLSTÅND, KONTINUERLIGA BESLUT

- ▶ Exempel på **förlustfunktioner** när både  $a$  och  $\theta$  är kontinuerliga:

- ▶ **Linjär**:  $L(a, \theta) = |a - \theta|$
- ▶ **Kvadratisk**:  $L(a, \theta) = (a - \theta)^2$
- ▶ **Lin-Lin**:

$$L(a, \theta) = \begin{cases} c_1 \cdot |a - \theta| & \text{if } a \leq \theta \\ c_2 \cdot |a - \theta| & \text{if } a > \theta \end{cases}$$

- ▶ Exempel:

- ▶  $\theta$  antalet efterfrågade produkter
- ▶  $a$  antal produkter i lager
- ▶ Nyttä

$$U(a, \theta) = \begin{cases} p \cdot \theta - c_1(a - \theta) & \text{om } a > \theta \text{ [för stort lager]} \\ p \cdot a - c_2(\theta - a)^2 & \text{om } a \leq \theta \text{ [för litet lager]} \end{cases}$$

# OPTIMALA BESLUT

- ▶ Exempel på vanlig beslutsregel: **Minimax**. Välj det beslut som minimerar den maximala förlusten.
- ▶ Bayes: Välj det beslut som **maximerar förväntad nytta** a posteriori:

$$a_{bayes} = \operatorname{argmax}_{a \in \mathcal{A}} \mathbb{E}[U(a, \theta)],$$

där  $\mathbb{E}$  är väntevärdet med avseende på aposteriorn  $p(\theta|Data)$ .

- ▶ I praktiken: simulera  $\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(N)}$  från  $p(\theta|Data)$  och approximera

$$\mathbb{E}[U(a, \theta)] \approx N^{-1} \sum_{i=1}^N U(a, \theta^{(i)})$$

- ▶ **Separationsprincipen:**

1. Ta först fram  $p(\theta|Data)$  ...
2. därefter  $U(a, \theta)$  och slutligen ...
3. välj det  $a \in \mathcal{A}$  som maximerar  $\mathbb{E}[U(a, \theta)]$ .

# VÄNTEVÄRDE, MEDIAN ELLER TYPVÄRDE?

- ▶ Hur kan vi bäst sammanfatta en aposteriorifördelning  $p(\theta|Data)$  med ett enda tal?
- ▶ Att välja en punktskattning är ett beslutsproblem.
- ▶ Valet beror på din förlustfunktion:
  - ▶ **Linjär förlust** → Posterior median är optimal
  - ▶ **Quadratic loss** → Posteriorväntevärdet  $\mathbb{E}(\theta|Data)$  är optimal
  - ▶ **Lin-Lin loss** →  $c_1/(c_1 + c_2)$  kvantilen i posteriorn är optimal
  - ▶ **Noll-ett förlust** → Posterior typvärdet är optimalt

# FÖRLUSTFUNKTIONER

