

TDAB01 Sannolikhetslära och Statistik

Jose M. Peña
IDA, Linköpings Universitet

Föreläsning 12

- ▶ Enkel regression, minsta kvadratmetoden, och R^2
- ▶ Konfidensintervall och hypotestest för lutning
- ▶ Konfidensintervall för prediktion
- ▶ Prediktionsintervall för individuell responsvariabel

Enkel regression, minsta kvadratmetoden, och R^2

- ▶ Regression: Prediktera $E[Y|X = x]$ där Y är en slumpvariabel (responsvariabel eller beroende variabel) och $X = x$ är en observation (förklarandevariabel eller oberoende variabel).
- ▶ Obs. att vi vill prediktera en populations parameter.
- ▶ Linjär regression: Antag $Y|X = x \sim \mathcal{N}(\mu(x), \sigma^2)$ och $E[Y|X = x] = \mu(x) = \beta_0 + \beta_1 x$ där
 - ▶ β_0 är intercepten, och
 - ▶ β_1 är lutningen.
- ▶ Minsta kvadratmetoden eller maximum likelihood metoden för att estimerar β_0 och β_1 :
 - ▶ $b_0 = \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$, och
 - ▶ $b_1 = \hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}$.
- ▶ $SS_{TOTAL} = \sum_i (y_i - \bar{y})^2$ = den **totala** variationen av Y i strickprovet.
- ▶ $SS_{REG} = \sum_i (\hat{y}_i - \bar{y})^2$ = den variationen **förklarad** av modellen.
- ▶ $SS_{ERR} = \sum_i (y_i - \hat{y}_i)^2$ = den variationen **inte** förklarad av modellen
 $= SS_{TOTAL} - SS_{REG}$.
- ▶ $R^2 = \frac{SS_{REG}}{SS_{TOTAL}}$ = **andelen** av den totala variationen förklarad av modellen.
- ▶ Obs. $0 \leq R^2 \leq 1$. Dessutom, $R^2 = r^2$ = kvadrerad sampling korrelationskoefficienten mellan X och Y .

Konfidensintervall och hypotestest för lutning

- ▶ **Trick:** $\sum_i (x_i - \bar{x}) = \sum_i x_i - n\bar{x} = 0$ och då

$$S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y}) = \sum_i (x_i - \bar{x})y_i - \bar{y} \sum_i (x_i - \bar{x}) = \sum_i (x_i - \bar{x})y_i$$

- ▶ $b_1 = \frac{S_{xy}}{S_{xx}} = \frac{\sum_i (x_i - \bar{x})y_i}{S_{xx}}$ och då b_1 är en linjär funktion av y_i och då **normal** fördelad.
- ▶ $E[b_1] = \frac{\sum_i (x_i - \bar{x})E[y_i]}{S_{xx}} = \frac{\sum_i (x_i - \bar{x})(\beta_0 + \beta_1 x_i)}{S_{xx}} = \frac{\beta_1 \sum_i (x_i - \bar{x})x_i}{S_{xx}} = \beta_1$ och då b_1 är en **väntevärdesriktig** estimator av β_1 .
- ▶ $var[b_1] = \frac{\sum_i (x_i - \bar{x})^2 var[y_i]}{S_{xx}^2} = \frac{\sigma^2}{S_{xx}}$.
- ▶ Nu kan vi bygga konfidensintervall och hypotestest för lutningen baserade på t -fördelningen, eftersom σ^2 brukar vara okänd.
 - ▶ $(1 - \alpha)100\%$ tvåsidigt konfidensintervall:

$$b_1 \pm t_{\alpha/2} \frac{s}{\sqrt{S_{xx}}}$$

där t -fördelningen har $n - 2$ frihetsgrader, och $s^2 = SS_{ERR}/(n - 2)$. För tekniskt varför $n - 2$ istället för $n - 1$. Se sida 371 eller 386 i Baron.

- ▶ Hypotestest $H_0: \beta_1 = B$ vs $H_A: \beta_1 \neq B$:

$$t = \frac{b_1 - B}{s/\sqrt{S_{xx}}}$$

som har en t -fördelningen har $n - 2$ frihetsgrader. Ta $B = 0$ för att pröva om det finns en linjär relation mellan X och Y .

Konfidensintervall och hypotestest för lutning

- ▶ $b_0 = \bar{y} - b_1 \bar{x} = \frac{\sum_i y_i}{n} - \frac{\sum_i (x_i - \bar{x}) y_i \bar{x}}{S_{xx}}$ och då b_0 är en linjär funktion av y_i och då **normal** fördelad.
- ▶ $E[b_0] = \frac{\sum_i E[y_i]}{n} - E[b_1] \bar{x} = \frac{\sum_i (\beta_0 + \beta_1 x_i)}{n} - \beta_1 \bar{x} = \beta_0 + \beta_1 \bar{x} - \beta_1 \bar{x} = \beta_0$ och då b_0 är en **väntevärdesriktig** estimator av β_0 .
- ▶ Se Example 11.6 i Baron.

Konfidensintervall för prediktion

- ▶ $\mu_* = \mu(x_*) = E[Y|X = x_*] = \beta_0 + \beta_1 x_*$ estimeras av
 $\hat{y}_* = \hat{\beta}_0 + \hat{\beta}_1 x_* = \bar{y} - b_1 \bar{x} + b_1 x_* = \bar{y} + b_1 (x_* - \bar{x}) = \frac{\sum_i y_i}{n} + \frac{\sum_i (x_i - \bar{x}) y_i (x_* - \bar{x})}{S_{xx}}$
 $\sum_i \left(\frac{1}{n} + \frac{\sum_i (x_i - \bar{x})(x_* - \bar{x})}{S_{xx}} \right) y_i$ och då \hat{y}_* är en linjär funktion av y_i och då **normal** fördelad.
- ▶ Obs. att vi predikterar en **populations parameter**.
- ▶ $E[\hat{y}_*] = E[b_0] + E[b_1]x_* = \beta_0 + \beta_1 x_* = \mu_*$ och då \hat{y}_* är en **väntevärdesriktig** estimator av μ_* .
- ▶ $var[\hat{y}_*] = \sum_i \left(\frac{1}{n} + \frac{\sum_i (x_i - \bar{x})(x_* - \bar{x})}{S_{xx}} \right)^2 var(y_i) = \sigma^2 \left(\frac{1}{n} + \frac{(x_* - \bar{x})^2}{S_{xx}} \right)$.
- ▶ $(1 - \alpha)100\%$ tvåsidigt konfidensintervall:

$$\hat{y}_* \pm t_{\alpha/2} s \sqrt{\frac{1}{n} + \frac{(x_* - \bar{x})^2}{S_{xx}}}$$

där t -fördelningen har $n - 2$ frihetsgrader, och $s^2 = SS_{ERR}/(n - 2)$.

Prediktionsintervall för individuell responsvariabel

- ▶ Ett konfidensintervall för \hat{y}_* representerar osäkerheten om **populationens väntevärde** vid $X = x_*$. Men hur ser osäkerheten för ett faktiskt y -värde ut om $X = x_*$?
- ▶ Obs. att vi **inte** längre predikterar en populations parameter utan en **slumpvariabel**, dvs vi predikterar inte väntevärdet för stoppsträckan när jag kör 50 km/t, utan stoppsträckan när jag kör 50 km/t, dvs utfallet av en körning istället för genomsnittet av många körningar.
- ▶ 95%-igt **prediktionsintervall** för y -värdet är ett intervall $[a, b]$ sådant att

$$P(a \leq y \leq b | X = x_*) = 0.95$$

där a , b och y är slumpvariabler, dvs y också !

- ▶ **Prediktera** $Y = \hat{y}_*$. Obs. att $y - \hat{y}_*$ är normal fördelad, eftersom y och \hat{y}_* är normal fördelade. Dessutom,

$$E[y - \hat{y}_*] = 0 \text{ och } sd(y - \hat{y}_*) = \sqrt{\text{var}(y) + \text{var}(\hat{y}_*)} = \sigma \sqrt{1 + \frac{1}{n} + \frac{(x_* - \bar{x})^2}{S_{xx}}}$$

Då, $\frac{y - \hat{y}_* - E[y - \hat{y}_*]}{sd(y - \hat{y}_*)}$ är t -fördelad. Då,

$$\hat{y}_* \pm t_{\alpha/2} s \sqrt{1 + \frac{1}{n} + \frac{(x_* - \bar{x})^2}{S_{xx}}}$$

där t -fördelningen har $n - 2$ frihetsgrader, och $s^2 = SS_{ERR}/(n - 2)$.

Prediktionsintervall för individuell responsvariabel

- ▶ $(1 - \alpha)100\%$ konfidensintervall:

$$\hat{y}_* \pm t_{\alpha/2} s \sqrt{\frac{1}{n} + \frac{(x_* - \bar{x})^2}{S_{xx}}}$$

- ▶ $(1 - \alpha)100\%$ prediktionsintervall:

$$\hat{y}_* \pm t_{\alpha/2} s \sqrt{1 + \frac{1}{n} + \frac{(x_* - \bar{x})^2}{S_{xx}}}$$

- ▶ Prediktionsintervallet är bredare än konfidensintervallet, dvs prediktera en individuell responsvariabel är svårare än prediktera populationens väntevärde.
- ▶ Konfidensintervallet konvergerar mot 0 när n ökar, eftersom S_{xx} ökar också. Prediktionsintervallet konvergerar inte mot 0.
- ▶ Prediktionsintervallet är smalare om x_* ligger nära \bar{x} , dvs lättare att prediktera under "normala" omständigheter.
- ▶ Se Example 11.7 i Baron.

- ▶ Enkel regression, minsta kvadratmetoden, och R^2
- ▶ Konfidensintervall och hypotestest för intercept och lutning
- ▶ Konfidensintervall för prediktion
- ▶ Prediktionsintervall för individuell responsvariabel